



**Trabajo Final de
Análisis y Procesamiento de Señales:**

“Detección de actividad de drones a partir de señales RF públicas”

Universidad Nacional de San Martín
Ingeniería Electrónica

Docentes: Mariano Llamedo Soria, Francisco Hernán Ledesma,
David Ezequiel Benoit

María Serena Gil

masegil@estudiantes.unsam.edu.ar

Julio 2026

Índice

1	Introducción	3
1.1	Objetivos	3
1.2	Alcance	3
2	Fundamentos Teóricos	3
3	Dataset y particiones	5
4	Metodología	7
4.1	Organización del desarrollo	7
4.2	Preprocesamiento y segmentación	7
4.3	Características interpretables	7
4.4	Protocolo por grupos	7
5	Verificaciones sintéticas	8
6	Análisis con DroneRF	9
6.1	Tiempo, FFT y PSD	9
6.2	Ventaneo real y relleno con ceros	12
6.3	Potencia relativa por bandas	13
6.4	Filtros FIR, IIR y Transformada Z	14
7	Selección de configuración	15
8	Resultados de separabilidad	16
8.1	Desarrollo y evaluación reservada	16
8.2	Muestras excluidas del entrenamiento	17
8.3	Caso concreto: Phantom conectado	18
8.4	Sensibilidad al ruido	19
8.5	Pruebas complementarias de estabilidad	20
9	Aplicación interactiva	21
10	Discusión y limitaciones	22
11	Reproducibilidad	23
12	Conclusiones	23

Resumen

Este trabajo analiza señales de radiofrecuencia del dataset público DroneRF mediante herramientas de Análisis y Procesamiento de Señales. Se comparan registros de fondo y de actividad de dron en los dominios temporal y frecuencial mediante DFT/FFT, periodograma, densidad espectral de potencia por Welch, ventaneo, relleno con ceros, potencia relativa por bandas y filtros digitales FIR e IIR vinculados con la Transformada Z. Las herramientas se verifican primero con señales sintéticas de frecuencia y relación señal–ruido conocidas. Luego se procesan 158 archivos reales correspondientes a 79 grupos, separados antes de generar ventanas en 55 grupos de desarrollo, 12 de evaluación y 12 de demostración. Como comprobación secundaria se evalúa una jerarquía lineal para distinguir fondo o actividad de dron y, cuando la evidencia lo permite, proponer modelo y modo de operación. La separación binaria se sostuvo dentro del subconjunto y del sistema de adquisición de DroneRF; modelo y modo no conservaron el mismo desempeño en los grupos reservados. Una aplicación local reproduce progresivamente archivos previamente normalizados y muestra las etapas del procesamiento. Las amplitudes y potencias son relativas, por lo que los resultados no representan potencia física ni el funcionamiento de un detector operacional.

1. Introducción

Los drones comerciales utilizan enlaces inalámbricos para control, telemetría y video. Esos enlaces producen actividad de radiofrecuencia que puede estudiarse con técnicas de procesamiento digital de señales. En este trabajo se utilizan registros públicos de DroneRF para organizar señales discretas, reconstruir ejes temporales y frecuenciales, aplicar FFT, estimar la densidad espectral de potencia, estudiar el ventaneo y diseñar filtros digitales.

El análisis se desarrolla sobre los contenidos de Análisis y Procesamiento de Señales y compara registros de fondo con registros que contienen actividad de dron. Las características y la validación por grupos se incorporan al final como una comprobación cuantitativa de las diferencias observadas, sin reemplazar el análisis temporal y espectral que estructura el trabajo.

Todo el desarrollo fue implementado en Python y Jupyter Notebook, y está disponible en el siguiente repositorio de GitHub: <https://github.com/MSereGB/APS-DroneRF>.

1.1. Objetivos

- Organizar y procesar señales RF públicas sin depender de una adquisición propia.
- Verificar FFT, PSD, Welch, ventaneo, ruido, muestreo y cuantización con señales conocidas.
- Distinguir el efecto visual del relleno con ceros de la resolución física de la observación.
- Comparar fondo y actividad de dron en tiempo, frecuencia y potencia relativa por bandas.
- Diseñar filtros FIR e IIR y relacionarlos con $H(z)$, polos, ceros y estabilidad.
- Extraer características interpretables y evaluar su separabilidad sin mezclar grupos.
- Construir una demostración local que reproduzca progresivamente archivos de señales RF.

1.2. Alcance

El trabajo se realizó con señales RF públicas de DroneRF, organizadas en grupos originales con partes L/H y separadas en desarrollo, evaluación y muestras excluidas. Cada registro se procesó de forma incremental, removiendo su media y normalizando la amplitud para comparar formas y potencias relativas. Se aplicaron segmentación, análisis temporal, FFT, periodograma, PSD por Welch, ventaneo, relleno con ceros, integración por bandas y filtros FIR e IIR. También se extrajeron características simples y se evaluó su separabilidad mediante particiones por grupos. La aplicación local reproduce archivos como una simulación de adquisición y muestra las etapas del procesamiento sobre la señal cargada.

2. Fundamentos Teóricos

Las señales de DroneRF se tratan como secuencias discretas $x[n]$ muestreadas a frecuencia f_s . El período de muestreo es $T_s = 1/f_s$, una ventana de N muestras representa una duración $T = N/f_s$ y la separación entre bins de la DFT es:

$$\Delta f = \frac{f_s}{N}. \quad (1)$$

Antes de comparar registros, se remueve la media y se normaliza cada señal por su máximo absoluto. Esta operación preserva la forma relativa de cada registro y evita interpretar la amplitud como una medición de potencia física:

$$x_{\text{norm}}[n] = \frac{x[n] - \bar{x}}{\max_n |x[n] - \bar{x}|}. \quad (2)$$

La Transformada Discreta de Fourier se define como [5]:

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}. \quad (3)$$

La FFT es un algoritmo eficiente para obtener $X[k]$. Para una ventana $w[n]$, el tramo analizado es $x_w[n] = x[n]w[n]$. El periodograma estima la densidad espectral de potencia (PSD) a partir de ese único tramo. Con la normalización usada por las funciones de SciPy, su forma general es:

$$\hat{S}_{xx}(f_k) = \frac{1}{f_s \sum_{n=0}^{N-1} w^2[n]} \left| \sum_{n=0}^{N-1} x[n] w[n] e^{-j2\pi kn/N} \right|^2. \quad (4)$$

Para señales reales se utiliza la representación unilateral y se conserva la potencia equivalente del espectro bilateral. Welch divide la señal en varios tramos, aplica una ventana a cada uno y promedia sus periodogramas. De esta manera reduce la variación de la estimación, aunque la menor longitud de cada tramo y el ventaneo modifican la resolución [6]:

$$\hat{S}_{xx, \text{Welch}}(f) = \frac{1}{M} \sum_{m=1}^M \hat{S}_{xx,m}(f). \quad (5)$$

La observación finita de una señal equivale a multiplicarla por una ventana. La ventana rectangular conserva un lóbulo principal angosto, pero tiene lóbulos laterales altos. Las ventanas Hann, Hamming y Blackman cambian el compromiso entre resolución y fuga espectral [7]. En el flujo final se usa Hann, elegida con datos de desarrollo.

Para comparar amplitudes después del ventaneo se usa la ganancia coherente $G_c = N^{-1} \sum_n w[n]$. El ancho de banda equivalente de ruido, expresado en bins, es:

$$\text{ENBW} = \frac{N \sum_n w^2[n]}{(\sum_n w[n])^2}. \quad (6)$$

Las medidas temporales básicas incluyen energía, potencia media y valor eficaz (RMS):

$$E = \sum_n |x[n]|^2, \quad P_{\text{media}} = \frac{1}{N} \sum_n |x[n]|^2, \quad \text{RMS} = \sqrt{P_{\text{media}}}. \quad (7)$$

El factor de cresta relaciona el máximo con el RMS. Para describir la distribución frecuencial se emplean el centroide y el ancho de banda espectral:

$$C_f = \frac{\max_n |x[n]|}{\text{RMS}}, \quad f_c = \frac{\sum_k f_k S_{xx}[k]}{\sum_k S_{xx}[k]}, \quad B = \sqrt{\frac{\sum_k (f_k - f_c)^2 S_{xx}[k]}{\sum_k S_{xx}[k]}}. \quad (8)$$

Para resumir la PSD se integra su área dentro de bandas y se divide por la potencia total. Así, la potencia relativa de la banda B_i es:

$$p_i = \frac{\int_{B_i} S_{xx}(f) df}{\int S_{xx}(f) df}. \quad (9)$$

El relleno con ceros, también llamado *zero padding*, agrega ceros al final de una ventana antes de calcular la FFT. La separación de la grilla pasa a $\Delta f_{\text{grilla}} = f_s/N_{\text{FFT}}$, pero no aumenta el tiempo observado ni la capacidad física de separar componentes próximas. En las simulaciones con ruido se usa una relación señal–ruido (SNR) controlada, $\text{SNR} = 10 \log_{10}(P_s/P_n)$, donde P_s y P_n son las potencias de señal y ruido.

Un filtro digital de respuesta finita al impulso (FIR) o de respuesta infinita al impulso (IIR) queda descrito por:

$$H(z) = \frac{\sum_{k=0}^M b_k z^{-k}}{\sum_{k=0}^P a_k z^{-k}}. \quad (10)$$

Los ceros son las raíces del numerador y los polos son las raíces del denominador. Para un IIR causal, los polos estrictamente dentro del círculo unitario indican estabilidad. La respuesta en frecuencia se obtiene al evaluar $H(z)$ sobre $z = e^{j\omega}$.

La evaluación binaria usa exactitud balanceada, que da el mismo peso a fondo y dron aun cuando las cantidades sean diferentes:

$$\text{BA} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right). \quad (11)$$

3. Dataset y particiones

DroneRF contiene registros de fondo y señales asociadas a tres modelos: Bebop, AR Drone y Phantom. Bebop y AR tienen cuatro modos (conectado, vuelo estacionario, vuelo y video). Phantom solo tiene el modo conectado en esta versión del dataset [1, 2].

Cuadro 1: Etiquetas utilizadas del dataset DroneRF.

Código	Modelo	Modo
00000	Sin dron	Fondo
10000	Bebop	Conectado
10001	Bebop	Vuelo estacionario
10010	Bebop	Vuelo
10011	Bebop	Video
10100	AR	Conectado
10101	AR	Vuelo estacionario
10110	AR	Vuelo
10111	AR	Video
11000	Phantom	Conectado

Las letras L y H provienen de *low band* y *high band*. En la adquisición original se usaron dos receptores NI-USRP-2943R en simultáneo: como cada receptor puede capturar 40 MHz instantáneos, uno registró la mitad inferior del espectro Wi-Fi y el otro la mitad superior, completando 80 MHz [1]. Así, en un nombre como 11000L_3.csv, L identifica la subbanda baja de 2.400 a 2.440 GHz; H identifica la subbanda alta de 2.440 a 2.480 GHz. No son modelos de dron, modos de operación ni dos tramos temporales consecutivos: son dos mediciones simultáneas y complementarias del mismo experimento.

El código oficial calcula el espectro de cada banda y concatena L con H, ajustando la continuidad de amplitud, para visualizar el intervalo completo de 2.400 a 2.480 GHz [3]. En este trabajo se

preservan las dos bandas por separado para el análisis temporal y espectral de cada archivo, y las predicciones se resumen primero por banda y luego se combinan con igual peso. Esto mantiene la trazabilidad de la adquisición y evita perder actividad que podría ocupar solamente una de las dos mitades del espectro. Por esa misma razón L y H comparten `group_id` y partición; una banda aislada puede mostrarse para analizar su forma de onda o su PSD, pero no habilita por sí sola una decisión de actividad.

La partición se congeló antes de calibrar:

Cuadro 2: Composición del subconjunto multiclase DroneRF v2.

Partición	Grupos	Archivos L/H	Uso
Desarrollo	55	110	Selección, particiones y umbrales
Evaluación reservada	12	24	Una evaluación final
Muestras excluidas	12	24	Demostración desde archivos no entrenados
Total	79	158	14,07 GiB (15,11 GB)

Los 158 archivos tienen hash SHA-256 y etiquetas explícitas en `data/manifests/dronerf_demo_v2_manifest.json`. La frecuencia de muestreo usada para las partes crudas L/H es 40 MHz, de acuerdo con la documentación y el código asociado al dataset. El eje positivo se representa entre 0 y 20 MHz sin atribuir una portadora física.




Figura 1: Cantidad de grupos originales en cada partición. La separación se realiza antes de generar ventanas.

La figura muestra que los grupos se asignaron a una única partición antes de segmentar los archivos. Como las ventanas L/H de un mismo segmento conservan el mismo identificador, la comparación posterior entre desarrollo, evaluación y demostración no usa tramos derivados del mismo registro en dos etapas distintas.

4. Metodología

4.1. Organización del desarrollo

El desarrollo se organizó en Python y Jupyter Notebook. Los notebooks presentan el recorrido de forma lineal: verificaciones sintéticas, exploración del dataset, tiempo y frecuencia, ventaneo y bandas, filtros digitales, características y resultados finales. Las funciones repetidas se mantienen en módulos reutilizables y los scripts permiten repetir la preparación de datos, la extracción de características, la evaluación y la exportación de figuras sin depender de una ejecución manual del notebook.

4.2. Preprocesamiento y segmentación

Cada CSV se procesa de forma incremental. Se remueve la media y se divide por el máximo absoluto del registro. La configuración final usa $N = 1024$, salto de 512 muestras, ventana Hann y 100 ventanas distribuidas de forma determinística por cada parte. Se obtienen 200 ventanas por grupo. La corrida de desarrollo y evaluación contiene 13.400 ventanas de 67 grupos; las 12 muestras de demostración se procesan aparte.

La normalización por registro permite comparar formas relativas, pero elimina diferencias de escala absoluta. Es una decisión coherente con la ausencia de calibración instrumental.

4.3. Características interpretables

Por ventana se calculan RMS, energía, potencia media, pico, factor de cresta, frecuencia dominante, máximo y potencia total de PSD, centroide espectral, ancho de banda y potencia relativa por bandas. Welch usa tramos de 256 muestras. Se probaron particiones de 4, 10 y 20 bandas uniformes sobre 0–20 MHz; las cuatro bandas de 5 MHz se mantienen para explicar los ejemplos y las 20 bandas de 1 MHz se usan en la configuración calibrada.

4.4. Protocolo por grupos

La evaluación se implementa mediante exclusión completa por grupos. Los 55 grupos de desarrollo se dividen cinco veces, manteniendo proporciones de clase y evitando que las ventanas de un mismo segmento aparezcan a ambos lados de una partición. En cada repetición, la normalización de las características se ajusta solamente con los grupos de entrenamiento. Como referencia se usa un clasificador que no aprende de las características; el modelo de comparación es una regresión logística lineal con pesos balanceados. Este esquema toma como punto de partida la segmentación y representación espectral usada por Medaiyese, Syed y Lauf, adaptada al análisis clásico desarrollado en este trabajo [4].

Las predicciones de las ventanas se agregan primero por parte y después se combinan L/H con igual peso. Las métricas se calculan por grupo original, no por ventana. El umbral fondo/dron y los márgenes de rechazo se obtienen solamente con predicciones de grupos que quedaron fuera del ajuste correspondiente dentro del desarrollo.

La decisión es jerárquica:

1. fondo o actividad de dron;
2. si hay actividad, modelo Bebop, AR o Phantom;
3. para Bebop o AR, modo conectado, vuelo estacionario, vuelo o video.

Si el margen entre las dos primeras hipótesis es pequeño se informa *No concluyente*. Una etapa solo se considera informativa si supera la referencia en al menos cuatro de las cinco particiones de desarrollo y además conserva separabilidad en la evaluación reservada. Con este criterio, modelo y modos quedan deshabilitados y se informa *No concluyente*.

5. Verificaciones sintéticas

Antes de analizar DroneRF se probaron las funciones con señales conocidas. Una senoidal de 180 Hz muestreada a 2 kHz produjo un máximo de FFT exactamente en 180 Hz, con $\Delta f = 1$ Hz.




Figura 2: FFT de una senoidal conocida. La frecuencia detectada coincide con la esperada.

El máximo de la FFT coincide con la frecuencia fijada al generar la senoidal. Este control permite comprobar que la construcción del eje frecuencial y el cálculo de Δf son consistentes antes de aplicarlos a registros RF.

En una suma de senoidales con ruido, el periodograma conserva una variación punto a punto mayor que Welch. Este resultado permite justificar por qué Welch se usa como estimador principal para las comparaciones reales.




Figura 3: Periodograma y Welch sobre una señal sintética con componentes conocidas y ruido.

Las componentes conocidas se mantienen en ambas estimaciones, pero el periodograma muestra mayor variación entre bins. Welch conserva la ubicación de las componentes y suaviza esa variación mediante el promedio de tramos, por eso se adopta para las comparaciones reales.

La comparación de ventanas muestra el compromiso esperado: la rectangular tiene mayor fuga

espectral, mientras Hann, Hamming y Blackman reducen los lóbulos laterales con distintos anchos de lóbulo principal.




Figura 4: Efecto del ventaneo sobre una componente que no coincide exactamente con un bin de la DFT.

La ventana rectangular concentra un lóbulo principal más angosto, aunque deja lóbulos laterales más altos. Hann, Hamming y Blackman reducen esa energía lateral con un lóbulo principal más ancho, que es el compromiso que luego se verifica sobre señales DroneRF.

También se verificaron aliasing al reducir f_s , mejora del error de cuantización al aumentar la cantidad de bits y pérdida de contraste espectral al disminuir la SNR. Estas pruebas controladas no reemplazan los datos reales: confirman que las funciones responden como se espera.

6. Análisis con DroneRF

6.1. Tiempo, FFT y PSD

Para mantener la comparación estable se fijaron los grupos `dronerf_00000_0` y `dronerf_10000_0`, parte L. Para que un pico aislado no deje plana a la señal completa, cada vista general usa límites verticales robustos, dados por los percentiles 0,5 y 99,5 del registro. Por eso esa escala permite leer la forma temporal, pero no comparar amplitudes entre paneles. El detalle corresponde, en cada caso, a la ventana de 1024 muestras cuyo RMS queda más cerca de la mediana de las primeras veinte ventanas. De esta manera el zoom no se elige buscando manualmente un tramo llamativo.




Figura 5: Primeros 512 μs y ampliación reproducible de un registro de fondo y uno de Bebop conectado, ambos de la parte L. Los rectángulos marcan el intervalo ampliado.

La forma local de las oscilaciones cambia entre los dos ejemplos y el zoom permite verla sin que la vista general quede dominada por un pico aislado. Al trabajar con una misma longitud de ventana se pueden comparar tramos temporales equivalentes antes de pasar al dominio frecuencial. Como las escalas generales son robustas e independientes, la amplitud se compara mediante RMS y pico, no por la altura de ambos paneles; una diferencia temporal aislada tampoco constituye por sí sola una regla general de detección.

La FFT se calculó sobre $N = 100\,000$ muestras con ventana Hann. Con $f_s = 40\text{ MHz}$ se obtiene $\Delta f = f_s/N = 400\text{ Hz}$. Además del espectro completo se muestra la banda de 5 MHz con mayor diferencia de potencia relativa entre estos dos registros; en este caso, 10–15 MHz.




Figura 6: Magnitud de FFT completa y ampliación de la banda de 5 MHz con mayor diferencia relativa entre los ejemplos fijados.

La FFT permite localizar componentes y comparar la forma de los dos espectros con una grilla de frecuencia conocida. La diferencia vertical global está influida por la normalización de cada registro por su máximo: expresa diferencias relativas de RMS y factor de cresta, no potencia RF absoluta ni ocupación exclusiva de una banda. Los máximos describen solamente el par graficado

y no identifican por sí solos un dron.

Welch se calculó con ventana Hann, $n_{\text{perseg}}=4096$ y 50 % de solapamiento. Su grilla es de aproximadamente 9,77 kHz. Al promediar periodogramas, la curva es más estable que una única realización y facilita comparar la distribución relativa de potencia.




Figura 7: PSD relativa por Welch: nivel obtenido después de normalizar cada registro, forma espectral normalizada por área y ampliación de la banda seleccionada para la FFT.

El promediado de Welch reduce la variación propia de un periodograma aislado y deja más visible la forma global de la PSD. En el notebook también se compara el periodograma real: conserva los mismos máximos principales, pero presenta más oscilaciones locales. La separación vertical entre las curvas se interpreta junto con la PSD normalizada por área y con las potencias relativas por bandas, ya que las señales fueron normalizadas por registro.

Para revisar si el contenido frecuencial permanece constante, el registro de Bebop se dividió en cuatro tramos temporales de igual longitud y se calculó una FFT para cada uno.




Figura 8: Comparación del contenido espectral en cuatro tramos temporales consecutivos del mismo registro de Bebop conectado.

Los dos primeros tramos presentan menor nivel relativo que los dos últimos, aunque varios máximos aparecen en posiciones semejantes. Esto muestra que el registro no es perfectamente estacionario y justifica distribuir las ventanas a lo largo del archivo, en lugar de tomar solamente su comienzo.

6.2. Ventaneo real y relleno con ceros

El efecto de las ventanas también se evaluó sobre datos reales, usando la ventana L número 50 de las muestras excluidas `sin_dron/muestra_01.npz` y `phantom/conectado/muestra_01.npz`. Se compararon rectangular, Hann, Hamming y Blackman, corrigiendo la ganancia coherente para que la atenuación propia de cada ventana no se confunda con una diferencia de amplitud de la señal.




Figura 9: Efecto del ventaneo sobre una ventana real de fondo y otra de Phantom conectado. La columna derecha amplía $\pm 0,6$ MHz alrededor del máximo obtenido con Hann.

Las cuatro curvas conservan la estructura general, pero cambian la dispersión alrededor de los máximos y el ancho aparente de las componentes. Reducir la fuga espectral ensancha el lóbulo principal y aumenta el ancho de banda equivalente de ruido. Cuando varios máximos tienen magnitudes muy próximas, la posición del mayor puede cambiar con la ventana; por eso un pico aislado no se usa como identificador.

Cuadro 3: Métricas de las ventanas y posición del máximo en los dos ejemplos reales.

Muestra	Ventana	Gan. coh.	ENBW [bins]	$f_{\text{máx}}$ [MHz]
Sin dron	Rectangular	1,00	1,000	5,0000
Sin dron	Hann	0,50	1,500	5,0000
Sin dron	Hamming	0,54	1,363	5,0000
Sin dron	Blackman	0,42	1,727	10,6641
Phantom	Rectangular	1,00	1,000	19,4336
Phantom	Hann	0,50	1,500	19,4238
Phantom	Hamming	0,54	1,363	19,4238
Phantom	Blackman	0,42	1,727	0,0684

Para estudiar la representación gráfica se comparó una DFT de $N = 1024$ muestras con una FFT de $N_{\text{FFT}} = 8192$. En ambos casos el tiempo observado es $N/f_s = 25,6 \mu\text{s}$. Sin relleno, la separación de la grilla es 39,06 kHz; con zero padding pasa a 4,88 kHz.




Figura 10: Relleno con ceros sobre una senoidal fuera de bin y sobre el ejemplo Phantom. Se conservan las 1024 muestras y solo cambia la cantidad de puntos de la FFT.

La curva con 8192 puntos dibuja con más continuidad la forma del lóbulo y permite ubicar visualmente mejor su máximo. Agregar ceros interpola más puntos de la DTFT muestreada por la DFT, pero no aumenta el tiempo de observación ni la resolución física: dos componentes no separables con 1024 muestras siguen sin serlo después del relleno.

6.3. Potencia relativa por bandas

La integración en cuatro bandas de 5 MHz resume la forma de la PSD. Las dos muestras reparten potencia en todo el semiespectro y las diferencias entre estas bandas anchas son pequeñas. Por lo tanto, este resumen no separa las clases por sí solo; su utilidad es mostrar por qué la configuración cuantitativa combina veinte bandas de 1 MHz con otras características temporales y espectrales.




Figura 11: Potencia relativa mediana de 100 ventanas L de fondo y 100 de Phantom conectado en cuatro bandas de 5 MHz.

El resumen conserva diferencias entre zonas del espectro sin depender de un único máximo. Integrar la PSD transforma una curva de muchos puntos en porcentajes comparables. Una banda ancha puede ocultar componentes estrechas, por lo que el resultado depende de los bordes elegidos y se interpreta junto con la PSD completa.

6.4. Filtros FIR, IIR y Transformada Z

Se diseñó un FIR de orden 400 mediante ventana de Hamming y un IIR Butterworth de orden 8. Ambos son pasa banda entre 9,260 y 10,760 MHz, alrededor de una componente del ejemplo de dron. La banda sirve para estudiar el filtrado; no se presenta como banda universal de detección.




Figura 12: Respuesta en frecuencia de los filtros FIR e IIR pasa banda.

Ambos filtros conservan la banda elegida y atenúan las regiones externas. El FIR de orden 400 presenta una transición más abrupta y mayor atenuación fuera de banda. El IIR logra un pasabanda semejante con un orden mucho menor, aunque con una transición más gradual.

El IIR posee radio máximo de polo 0,9562, menor que uno, por lo que es estable. La diferencia máxima entre evaluar $H(z)$ sobre el círculo unitario y usar `scipy.signal.freqz` fue $4,88 \times 10^{-13}$.




Figura 13: Plano z del filtro IIR. Todos los polos se encuentran dentro del círculo unitario.

Los polos quedan dentro del círculo unitario, por lo que el IIR causal es estable. Esta representación vincula el filtro aplicado en frecuencia con la expresión de $H(z)$ y con el criterio de estabilidad estudiado para sistemas discretos.




Figura 14: PSD del registro de dron antes y después de aplicar los filtros FIR e IIR pasa banda.

La proporción de potencia dentro de la banda elegida pasa de 0,344 en la entrada a 0,998 con el FIR y 0,977 con el IIR. El filtrado se aplicó en ambos sentidos para evitar un corrimiento de fase durante el análisis de archivos guardados. Esta operación es no causal y se utiliza para comparar espectros fuera de línea; una implementación sobre hardware en tiempo real requeriría aplicar cada filtro en sentido directo y considerar su retardo.

Los filtros se mantienen como análisis académico. No se incorporaron obligatoriamente al clasificador porque el objetivo era conservar características simples y evitar atribuir una mejora que no fuera estable en desarrollo.

7. Selección de configuración

Se compararon configuraciones predefinidas solamente con desarrollo. La prioridad fue la exactitud balanceada media de las etapas; ante diferencias menores a 0,02 se eligió menor dispersión y luego la opción más simple.

Cuadro 4: Resumen de sensibilidad de longitud y ventana.

Configuración	Exactitud balanceada media	Dispersión media
$N = 256$, Hann	0,558	0,053
$N = 512$, Hann	0,608	0,094
$N = 1024$, Hann	0,613	0,078
$N = 2048$, Hann	0,600	0,080
$N = 512$, Hamming	0,608	0,119
$N = 512$, Blackman	0,583	0,094

$N = 1024$ alcanzó el mayor valor medio y redujo la dispersión respecto de la configuración de referencia $N = 512$. Con $N = 1024$, la comparación de 4, 10 y 20 bandas produjo valores medios 0,556, 0,600 y 0,604 respectivamente; se eligieron 20 bandas por obtener el mayor valor medio y la menor dispersión entre las opciones cercanas.




Figura 15: Comparación de longitudes de ventana y ventanas de análisis realizada únicamente con desarrollo.

Las configuraciones producen diferencias moderadas en la exactitud balanceada media y en su dispersión entre particiones. La selección se hizo solamente con desarrollo, privilegiando $N = 1024$ con ventana Hann por su equilibrio entre resultado medio y estabilidad, antes de consultar evaluación o muestras excluidas.

Después de esta selección se fijaron las características, los modelos, los umbrales y los márgenes. Los grupos de evaluación y demostración no habilitaron nuevos ajustes.

8. Resultados de separabilidad

8.1. Desarrollo y evaluación reservada

Cuadro 5: Exactitud balanceada por grupo en la jerarquía.

Etapa	Referencia	Desarrollo	Evaluación reservada
Fondo / dron	0,500	1,000	1,000
Modelo	0,333	0,583	0,167
Modo Bebop	0,250	0,250	0,000
Modo AR	0,250	0,350	0,250




Figura 16: Separabilidad por nivel dentro del subconjunto DroneRF. Fondo/dron conserva el resultado en evaluación; modelo y modo no muestran el mismo comportamiento.

La diferencia entre la primera etapa y las siguientes es clara: fondo/dron se mantiene por encima de la referencia nula, mientras que modelo y modo no conservan el mismo comportamiento en evaluación. Por eso la aplicación utiliza la primera etapa como comprobación secundaria de separabilidad y detiene la interpretación jerárquica cuando no hay respaldo suficiente.

La etapa fondo/dron alcanzó exactitud, exactitud balanceada, precisión, sensibilidad y F1 iguales a 1,000 en los 55 grupos de desarrollo evaluados fuera de su ajuste y en los 12 grupos reservados. Es un resultado del protocolo de laboratorio, no una prueba de generalización a otras capturas. En modelo, la cobertura diagnóstica de evaluación fue parcial y la exactitud balanceada 0,167. Modo Bebop quedó por debajo de la referencia y fue deshabilitado. Modo AR obtuvo 0,250, pero se calcula sobre solo cuatro grupos. Por esos resultados, la aplicación conservadora no habilita modelo ni modo.

8.2. Muestras excluidas del entrenamiento

Se construyeron doce paquetes NPZ desde los grupos reservados para demostración. Cada paquete contiene partes L/H y f_s ; la etiqueta esperada se mantiene en un catálogo separado y se consulta después de inferir. Un test verifica que esa etiqueta no ingrese al detector.

Cuadro 6: Resultados sobre muestras excluidas de entrenamiento y calibración.

Nivel	Exactitud balanceada	Cobertura	Grupos
Fondo / dron	1,000	1,000	12
Modelo	—	0,000	9
Modo	—	0,000	9

Las muestras excluidas mantienen la decisión de actividad al procesar juntas sus partes L/H. La ausencia de una etiqueta de modelo o modo responde al criterio de no comunicar una identificación que la evaluación reservada no sostiene.

En modelo y modo no corresponde calcular exactitud balanceada cuando la cobertura es cero:

la aplicación no emitió etiquetas en esos niveles. El valor se muestra como “—” y no como un desempeño nulo, porque es una decisión deliberada de no extender la conclusión más allá de la evidencia reservada.

Estas muestras nunca participaron en entrenamiento ni selección de parámetros. Sin embargo, sus etiquetas ya fueron reveladas en una pasada anterior, por lo que se las denomina *muestras excluidas* y no validación ciega independiente.

8.3. Caso concreto: Phantom conectado

Para recorrer el sistema completo se eligió `muestras_demo/phantom/conectado/muestra_01.npz`. El programa leyó las partes L/H, generó ventanas, calculó características temporales y espectrales y ejecutó la jerarquía sin recibir la etiqueta esperada. Recién después de terminar la inferencia se consultó el archivo separado de etiquetas.




Figura 17: Caso Phantom excluido: ventanas temporales L/H, FFT y PSD por Welch con ampliaciones sobre componentes relevantes.

L y H tienen escalas relativas diferentes, componentes distribuidas en todo el intervalo 0–20 MHz y contrastes pico–piso de 2,82 y 3,26 dB. La combinación de ambas partes y de muchas ventanas aporta más información que una sola frecuencia dominante. El piso se calcula como la mediana de la PSD expresada en dB relativos, por lo que no es una medición de ruido físico ni una estimación de SNR.

Cuadro 7: Resumen de características del caso Phantom, agregado sobre las ventanas procesadas.

Parte	RMS	Pico	Factor de cresta	Centroide [MHz]	Ancho [MHz]
L	$4,326 \times 10^{-4}$	$1,636 \times 10^{-3}$	3,449	10,824	6,203
H	$3,322 \times 10^{-3}$	$1,205 \times 10^{-2}$	3,353	10,657	6,230

La decisión binaria produjo un puntaje relativo de 0,839 frente a un umbral calibrado de 0,413, con margen 0,426. La hipótesis interna con mayor puntaje de modelo fue Phantom, pero la diferencia con la segunda fue solo 0,053 y la exactitud balanceada de modelo en la evaluación reservada fue 0,167. Por eso la aplicación no presenta modelo ni modo como identificación confirmada.




Figura 18: Potencia relativa en 20 bandas y salida jerárquica obtenida sin consultar la etiqueta del caso Phantom.

La distribución por bandas y las características producen una salida de actividad de dron. Al abrir el catálogo después, la actividad coincide con la etiqueta reservada, mientras que modelo y modo quedan deliberadamente no concluyentes. El resultado surge de resumir información temporal y frecuencial, no de memorizar el nombre del archivo. Una hipótesis interna de Phantom no corrige el bajo desempeño global de la identificación de modelo.

8.4. Sensibilidad al ruido

Sobre las doce muestras se agregó ruido blanco con SNR relativa controlada después de la normalización y se repitió cinco veces por nivel. La exactitud balanceada promedio fue 0,93 a 20 dB, 0,61 a 10 dB y entre 0,50 y 0,56 de -5 a 5 dB. No aparecieron falsas alarmas en estas perturbaciones, pero sí pérdidas de actividad: con ruido fuerte el detector deja de reconocer gran parte de los drones.

La tendencia es consistente con una degradación al disminuir la SNR, aunque los pequeños cambios no deben sobreinterpretarse porque hay solo doce grupos y el ruido agregado no reproduce un canal RF completo. La cuantización relativa mostró un límite similar: a 8 y 12 bits la exactitud balanceada fue 0,944 y 1,000, mientras que a 4 y 6 bits cayó a 0,500 por pérdidas, sin falsas alarmas. No se interpreta como una especificación de ADC porque la perturbación se aplica sobre ventanas normalizadas.

8.5. Pruebas complementarias de estabilidad

Se repitió cinco veces una validación cruzada anidada por grupos. En cada partición externa, los grupos de prueba quedaron fuera del ajuste del clasificador y de la selección del umbral. La exactitud balanceada quedó entre 0,956 y 0,989; no hubo falsas alarmas en las 50 exposiciones de fondo de esas repeticiones, aunque se perdieron entre uno y cuatro grupos de dron según la partición. Las repeticiones no son independientes entre sí, por lo que estos conteos describen estabilidad del protocolo y no una nueva población de señales.




Figura 19: Pruebas complementarias sobre la etapa fondo/dron: particiones repetidas por grupos, etiquetas permutadas, ruido blanco y cuantización relativa.

La figura reúne controles que cambian la partición o la señal. La validación anidada repite la separación de grupos y vuelve a elegir el umbral sin usar el grupo externo. El control con etiquetas permutadas rompe deliberadamente la relación entre señal y clase: si el resultado permaneciera alto, indicaría que el procedimiento está aprovechando una estructura ajena a las etiquetas reales. Este control se repitió cien veces.

Las cien permutaciones produjeron una exactitud balanceada media de 0,584 y un máximo de 0,850, siempre por debajo del promedio real de 0,978. Con la corrección habitual $(k+1)/(M+1)$, donde k es la cantidad de permutaciones que igualan o superan el resultado real y $M = 100$, el valor empírico es 0,0099. Este control apoya que la separación observada no surge solamente del procedimiento de partición, aunque sigue limitado al subconjunto analizado. Cuatro tramos temporales separados mantuvieron exactitud balanceada 1,000 con L/H presentes. En un diagnóstico inicial, al forzar el umbral calibrado con L/H sobre una única parte H, aparecieron dos falsas alarmas. Esa no es una salida permitida por la aplicación final: con la política vigente, L sola o H sola no emiten una decisión de actividad. La interfaz conserva sus gráficos y características, pero devuelve *No concluyente* si no están juntas L y H.

Se añadió un desafío negativo con cinco fondos de los segmentos 21–25 de DroneRF, extraídos después de fijar desarrollo, evaluación y demostración. Con los modelos y umbrales ya definidos,

los cinco quedaron por debajo del umbral y no hubo falsas alarmas. Sumados a los tres fondos de la evaluación reservada, son ocho grupos del mismo dataset; este conteo no estima una tasa general de falsas alarmas para otros receptores o ambientes.

Por último, se evaluó el sistema con seis controles sintéticos que no son registros DroneRF: ruido blanco, tonos, suma de tonos, modulación de amplitud y barrido lineal de frecuencia, todos con partes L/H simuladas. Algunos recibieron un puntaje lineal alto si se ignoraba el dominio de calibración. Por eso la aplicación compara la mediana de las características con el rango robusto aprendido solo en desarrollo. Los seis controles quedaron fuera de ese rango y retornaron *No concluyente*. Este control no identifica la fuente desconocida ni convierte la señal en fondo: únicamente evita extender la decisión fondo/dron más allá de DroneRF.

Como control adicional de calidad de entrada se usó el factor de cresta, que relaciona el pico de una ventana con su RMS. Su límite se calibró únicamente con las 55 agrupaciones de desarrollo: la mediana por parte no superó 3,572 y se fijó un límite conservador de 3,751. Los 55 grupos de desarrollo, los 12 de evaluación y las 12 muestras excluidas limpias quedaron dentro de ese rango. Luego, sin cambiar clasificador, umbral ni control de dominio, se inyectaron transitorios bipolares en 0,5 % de las muestras de las 12 entradas de demostración. En los 12 casos la aplicación devolvió *No concluyente*; no hubo falsas alarmas, pero tampoco se intentó detectar los nueve drones presentes. Esta salida conservadora protege la demostración frente a un artefacto sintético fuerte, no demuestra inmunidad frente a interferencias reales.

Los tonos añadidos conservan la decisión sobre estas muestras, mientras que los impulsos elevan el factor de cresta y activan el control de calidad. La salida no concluyente evita convertir un transitorio sintético intenso en una alarma, aunque también deja de emitir actividad para los drones afectados.

9. Aplicación interactiva

La aplicación se implementó con Gradio y funciona localmente sin conexión a internet. La primera pantalla es el instrumento de análisis: permite elegir una muestra de la biblioteca o arrastrar CSV, TXT, NPY, NPZ o MAT. Si el archivo no incluye metadatos se solicita f_s .

El flujo es:

archivo $\rightarrow$ lectura $\rightarrow$ normalización por registro $\rightarrow$ ventanas $\rightarrow$ características $\rightarrow$ modelos
calibrados $\rightarrow$ interpretación.

La reproducción progresiva procesa ventanas en orden temporal y actualiza entre dos y cinco veces por segundo. Antes de iniciar esa secuencia, el archivo completo se centra y se normaliza por su máximo, igual que los registros de calibración. Por eso la progresión simula la entrega de bloques ya acondicionados y no un preprocesamiento causal a 40 MHz. Un sensor real requeriría una escala fija, normalización por bloques o control automático de ganancia y una nueva calibración.

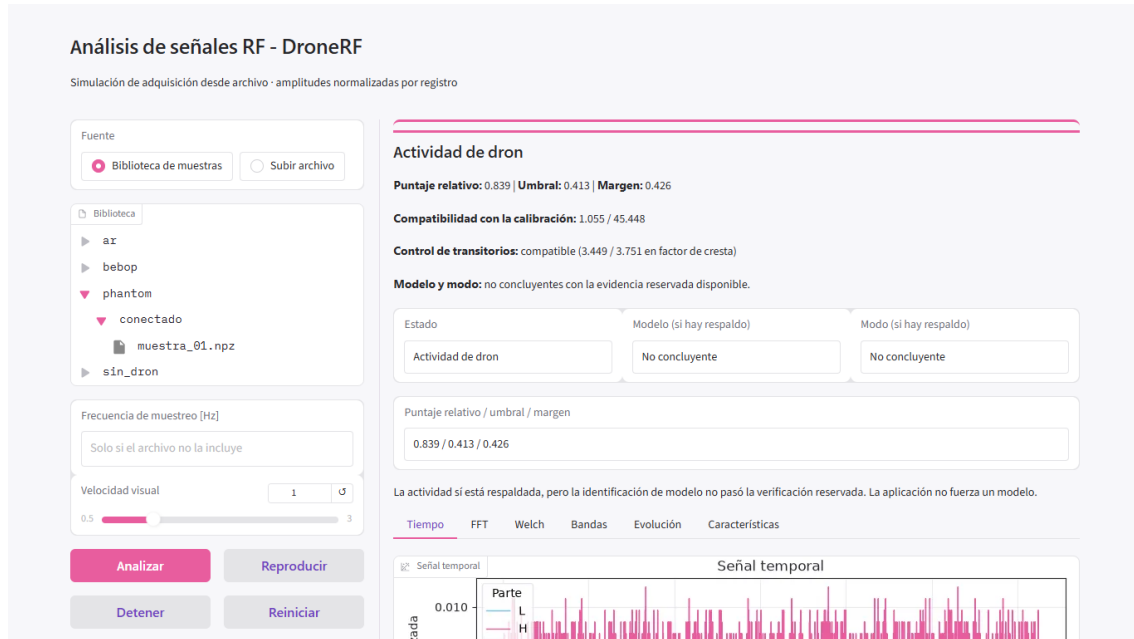


Figura 20: Aplicación local después de analizar la muestra Phantom conectada, antes de mostrar la etiqueta esperada.

La interfaz concentra la señal temporal, el contenido espectral, la potencia por bandas y las características que intervienen en la decisión. La salida visible es actividad de dron; la identidad de la muestra se consulta por separado después del procesamiento para mantener el mismo recorrido que tendría un archivo cargado durante la demostración.

La pantalla muestra señal temporal, FFT, Welch, potencia relativa por bandas, evolución del puntaje y tabla de características. El puntaje es relativo y no una probabilidad física. Si una etapa no tiene respaldo suficiente, la respuesta se detiene en el último nivel habilitado. La decisión de actividad requiere las partes L y H; un archivo con una sola parte queda como *No concluyente* para evitar trasladar un umbral calibrado con ambas partes a una condición que mostró falsas alarmas. Además, si las características quedan fuera del intervalo robusto observado en desarrollo, se conservan las gráficas pero se devuelve *No concluyente* antes de aplicar el puntaje de actividad. Esta precaución evita interpretar un archivo arbitrario como dron solo por el valor de un modelo lineal. Como control independiente, si la mediana del factor de cresta de L o H supera el rango visto en desarrollo, la aplicación también se detiene antes de decidir: interpreta esos transitorios como una entrada no apta para esta calibración, no como actividad de dron.

10. Discusión y limitaciones

El resultado más sólido es la diferencia fondo/dron dentro del subconjunto preparado. La PSD y la potencia por bandas muestran por qué las características espectrales aportan información. El análisis de filtros y Transformada Z completa los contenidos de Análisis y Procesamiento de Señales sin forzar el filtro dentro del detector.

Las vistas completa y ampliada mejoran la lectura sin cambiar la evidencia. La selección determinística de ventanas y bandas evita elegir después de mirar el resultado. Del mismo modo, el relleno con ceros se presenta como una grilla espectral más densa y no como una mejora de resolución física.

La identificación jerárquica también muestra un límite útil: obtener buena separación binaria no implica reconocer modelo y modo. Modelo cayó de 0,583 en desarrollo a 0,167 en evaluación, y

los modos no superaron a la referencia. Conservar estos resultados evita inflar el desempeño y justifica la salida *No concluyente*.

Las principales limitaciones son:

- 79 grupos provienen de un único dataset, sistema de adquisición y condiciones acotadas;
- la evaluación reservada contiene solo 12 grupos;
- las amplitudes normalizadas eliminan información absoluta y no hay calibración física;
- no se evalúan otros sensores, ambientes, distancias ni interferencias reales;
- el ruido sintético no modela por completo propagación, multitrayecto ni ocupación de canal;
- a SNR relativa baja aparecen pérdidas de actividad, aunque no se observaron falsas alarmas en esa prueba acotada;
- el umbral binario final requiere L y H; una parte aislada no se interpreta como decisión;
- una señal fuera del dominio DroneRF solo puede rechazarse como *No concluyente*; el control no identifica su fuente ni garantiza cobertura de interferencias reales;
- transitorios sintéticos intensos se bloquean por factor de cresta y pueden producir una pérdida deliberada de actividad; no se evaluaron transitorios de un receptor real;
- las muestras de demo están excluidas del ajuste, pero ya no son ciegas en sentido estricto;
- la aplicación reproduce archivos y no recibe una señal RF en tiempo real desde hardware.

Por estas razones no se extrapolan las métricas a un detector operacional. El trabajo demuestra un método reproducible y una simulación de laboratorio.

11. Reproducibilidad

El entorno probado usa Python 3.13.4 y dependencias registradas en `requirements-lock.txt`. Los datos pesados se mantienen fuera de Git y se localizan mediante `DATA_DIR`; el manifiesto del dataset registra etiquetas, particiones, tamaños y hashes. Cada corrida guarda su configuración, las características calculadas, los modelos y las métricas. Los comandos completos de instalación, ejecución y verificación se encuentran en el README del repositorio público.

Los notebooks 00–06 se ejecutan de arriba abajo y conservan sus salidas. Las pruebas automáticas controlan las dimensiones espectrales, estabilidad de filtros, conservación de potencia entre bandas, separación por grupos, ausencia de etiquetas durante la inferencia y compatibilidad entre características y modelos.

12. Conclusiones

El análisis temporal, la FFT y la PSD por Welch permitieron describir diferencias relativas entre fondo y actividad de dron. El ventaneo explicó el compromiso entre fuga y resolución, el relleno con ceros mejoró la lectura de los máximos sin añadir resolución física y los filtros FIR e IIR mostraron cómo aislar una banda y relacionarla con $H(z)$, polos, ceros y estabilidad.

La validación por grupos sostuvo la separación fondo/dron dentro del subconjunto y del sistema de adquisición de DroneRF. El caso Phantom recorrió el procesamiento completo y produjo una decisión de actividad antes de consultar su etiqueta. La misma evidencia no alcanzó para identificar

modelo y modo de manera confiable, por lo que la interfaz comunica una conclusión parcial en esos niveles.

El trabajo aporta un flujo reproducible de laboratorio que une datos públicos, procesamiento clásico de señales, evaluación sin mezcla de registros y una aplicación para reproducir archivos previamente acondicionados. Para trasladarlo a una adquisición real serían necesarios otros receptores y ambientes, calibración física y un preprocesamiento causal compatible con el hardware.

Referencias

- [1] M. F. Al-Sa'd, A. Al-Ali, A. Mohamed, T. Khattab y A. Erbad, *RF-based drone detection and identification using deep learning approaches: An initiative towards a large open source drone database*, Future Generation Computer Systems, 2019. <https://doi.org/10.1016/j.future.2019.05.007>.
- [2] DroneRF dataset, Mendeley Data. <https://data.mendeley.com/datasets/f4c2b4n755/1>.
- [3] Código asociado a DroneRF. <https://al-sad.github.io/DroneRF/>.
- [4] O. O. Medaiyese, A. Syed y A. P. Lauf, *Machine Learning Framework for RF-Based Drone Detection and Identification System*, arXiv:2003.02656, 2020. <https://arxiv.org/abs/2003.02656>.
- [5] A. V. Oppenheim y R. W. Schaffer, *Discrete-Time Signal Processing*, 3ra ed., Pearson, 2010.
- [6] P. D. Welch, *The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms*, IEEE Transactions on Audio and Electroacoustics, vol. 15, no. 2, pp. 70–73, 1967.
- [7] F. J. Harris, *On the use of windows for harmonic analysis with the discrete Fourier transform*, Proceedings of the IEEE, vol. 66, no. 1, pp. 51–83, 1978.